

**Komisija za študijske zadeve**

Univerza v Ljubljani, Fakulteta za računalništvo in informatiko

Večna pot 113, 1000 Ljubljana

## **Vloga za prijavo teme magistrskega dela**

**Kandidat: Matic Stare**

Matic Stare, študent/-ka magistrskega programa na Fakulteti za računalništvo in informatiko, zaprošam Komisijo za študijske zadeve, da odobri predloženo temo magistrskega dela z naslovom:

Slovenski: **Napovedovanje možnih trkov med vlaki in predori**

Angleški: **Predicting Possible Collisions Between Trains and Tunnels**

Tema je bila že potrjena lani in je ponovno vložena: **NE**

Izjavljam, da so spodaj navedeni mentorji predlog teme pregledali in odobrili ter da se z oddajo predloga strinjajo.

Magistrsko delo nameravam pisati v slovenščini.

Za mentorja/mentorico predlagam:

Ime in priimek: doc. dr. Uroš Čibej

Ustanova: Univerza v Ljubljani, Fakulteta za računalništvo in informatiko

Elektronski naslov: UroS.Cibej@fri.uni-lj.si

Za somentorja/somentorico predlagam:

Ime, priimek in naziv: /

Ustanova: /

Elektronski naslov: /

V Ljubljani, 30. januar 2025.

# PREDLOG TEME MAGISTRSKEGA DELA

## 1 Področje magistrskega dela

slovensko: računalništvo in informatika, računalniška geometrija, optimizacija v prometu  
angleško: computer science and informatics, computational geometry, traffic optimization

## 2 Ključne besede

slovensko: železniški promet, zaznavanje trkov, oblaki točk, optimizacija poti  
angleško: rail transport, collision detection, point clouds, path optimization

## 3 Opis teme magistrskega dela

### **Pretekle potrditve predložene teme:**

Predložena tema ni bila oddana in potrjena v preteklih letih.

### 3.1 Uvod in opis problema

V železniškem prometu je zagotavljanje varnosti v predorih ključnega pomena, še posebej pri dolgi in široki tovorni kompoziciji, ki se giblje skozi ozke in ukrivljene predore. Problem, ki ga obravnavam v tej magistrski nalogi, je zaznavanje morebitnih trkov med vlakom in stenami predora, ki nastanejo zaradi nepravilnega sledenja predpisanemu varnostnemu prostoru ali napak v modeliranju geometrije predora.

Motivacija za delo izhaja iz realnega izziva, ki sem ga prejel od podjetja Slovenske železnice. Ti so izrazili potrebo po razvoju avtomatiziranega sistema, ki bi omogočil natančno zaznavanje trkov med vlakom in predorom. Klasične metode, kot je uporaba minimalnega prereza, so v takšnih scenarijih nezadostne, saj ne upoštevajo kompleksne ukrivljenosti poti ali relativnih premikov vagona, ki lahko presežejo varnostne meje, zlasti v ostrih ovinkih. Problem je izrazit pri dolgi tovorni kompoziciji, kjer razlika med položajem sprednje in zadnje osi povečuje tveganje za trk. Poleg tega trenutne metode pogosto niso dovolj prilagodljive za različne geometrije predorov in vlakov.

V tej nalogi predlagam analitičen pristop k reševanju problema. Osnovna vhodna podatka sta oblaka točk predora in vlaka, ki ju bomo predhodno obdelali in pretvorili v 2D

pogled od zgoraj (bird's-eye view) v več plasteh. Na podlagi tega bomo določili kritične točke na vlaku, ki so ključne za zaznavanje trkov, ter izračunali krivulje, po katerih se te točke gibljejo med vožnjo. Analitično modeliranje teh krivulj bo omogočilo učinkovito zaznavanje trkov in izračun globine penetracije, kar bo pripomoglo k večji varnosti in optimizaciji železniškega prometa.

Naloga se umešča na področje računalniškega modeliranja in analize v prostoru ter pri naša novost v kombinaciji analitičnega modeliranja gibanja s prostorsko analizo, kar bo omogočilo hitrejšo in natančnejšo analizo trkov v primerjavi z obstoječimi metodami, ki temeljijo na »brute force« načinu.

## 3.2 Pregled sorodnih del

Na področju zaznavanja trkov v prostoru se pogosto uporabljajo metode, ki temeljijo na analizi oblakov točk in algoritmih prostorskega indeksiranja. Ena izmed najpogostejše uporabljenih tehnik je uporaba k-d dreves za učinkovito iskanje sosednjih točk v prostoru, kot je prikazano v delu **Schauerja in Nüchterja (2014)**[1]. Prednost njihovega pristopa je visoka računska učinkovitost pri analizi oblakov točk velikega obsega. Ker pa je točk zelo veliko, se poraja potreba po bolj pametnih izračunih trkov. Članek bo služil kot osnova za to magistrsko delo.

Drugo pomembno delo je **Klein in Zachmann (2004)**[2], kjer avtorja obravnavata zaznavanje trkov s pomočjo implicitnih površin, ustvarjenih iz oblakov točk. Njihov pristop je posebej uporaben pri obdelavi kompleksnih geometrij, vendar je računsko zahteven, kar lahko omejuje uporabo v realnem času.

Kot alternativo klasičnim metodam so **Hermann et al. (2014)**[3] razvili algoritme, ki temeljijo na vokselizaciji prostora. Ti algoritmi omogočajo hitro preverjanje prostorske zasedenosti, vendar lahko pri zelo natančnih analizah izgubijo detajle zaradi diskretizacije prostora.

V članku **Niwa (2016)**[4] je predstavljen pristop za zaznavanje trkov z metodo globinskih slik kar izboljša učinkovitost in pravilnost. Ta pristop omogoča zanesljivejše zaznavanje trkov v gostih oblakih točk, a ima še vedno veliko časovno, predvsem pa tudi prostorsko zahtevnost.

Avtorji v članku **Li (2020)**[5] pregledajo najnovejše pristope strojnega učenja za obdelavo LiDAR podatkov. Izpostavljajo, kako lahko globoko učenje izboljša zaznavanje in analizo oblakov točk v avtonomnih vozilih, še posebej pri neenakomernih in šumnih podatkih. Kljub napredku se metode soočajo z izzivi pri obdelavi velikih oblakov točk in zagotavljanju rezultatov v realnem času, kar omejuje njihovo uporabnost v hitro spreminjajočih se

okoljih.

Članek **Everett et al. (2021)[6]** predstavi sistem za izogibanje trkom v dinamičnih okoljih z uporabo globokega spodbujevalnega učenja. Prednost tega pristopa je prilagodljivost za različne scenarije in obdelava spremenljivega števila agentov brez strogih predpostavk o njihovem gibanju. Kljub temu metoda manj poudarja analizo geometrijskih lastnosti, kar jo omejuje pri natančnih prostorskih analizah, kot je analiza trkov med vlakom in predorom, zaradi česar je njena uporaba v tem kontekstu manj primerna.

Iz zgornjih del je razvidno, da večina obstoječih metod bodisi zanemarja dinamične lastnosti gibanja bodisi ne omogoča učinkovitega prilagajanja različnim geometrijam. Cilj moje naloge je preseči te omejitve z vključitvijo analitičnega modeliranja gibanja kritičnih točk in prekrivanjem teh krivulj z geometrijo predora, kar bo omogočilo natančnejše in hitrejše zaznavanje trkov. Zato sledita še dva članka, ki opisujeta krivulje, ki bi bile lahko uporabljene, oziroma so že uporabljene v železniškem prometu.

V članku **"Railway Transition Curves: A Review of the State-of-the-Art and Future Research"(2020) [7]** avtorji analizirajo prehodne krivulje, ki omogočajo gladek prehod med ravnimi in ukrivljenimi odseki železniških tirov. Glavna prednost teh krivulj je njihova sposobnost zmanjšanja sil in obrabe vozil ter tirnic, kar poveča udobje potnikov in zmanjša stroške vzdrževanja. Kljub temu se raziskave na tem področju še vedno soočajo z izzivi, kot so določanje optimalnih lastnosti krivulj za različne scenarije in vozne profile.

Drugo relevantno delo je **"The Characteristics of Long-Wave Irregularities in High-Speed Railway Vertical Curves and Method for Mitigation"(2024)[8]**, kjer avtorji predlagajo uporabo paraboličnih in sinusoidnih prehodnih krivulj za zmanjšanje dolgovalovnih nepravilnosti v vertikalnih profilih tirov. Prednost tega pristopa je zmanjšanje pospeškov pri prehodih, kar izboljša stabilnost vlaka in varnost potnikov. Slabost pa je, da metoda zahteva precizno načrtovanje in prilagoditev specifičnim konstrukcijskim zahtevam, kar lahko poveča začetne stroške implementacije.

### 3.3 Predvideni prispevki magistrske naloge

Magistrska naloga bo prispevala k razvoju natančnejših metod za zaznavanje trkov med vlakom in tunelom, z uporabo analitičnega modeliranja in algoritmov za simulacijo gibanja kritičnih točk vagona. V primerjavi z obstoječimi metodami, ki temeljijo na obdelavi oblakov točk in k-d dreves, bo predlagana rešitev omogočila hitrejšo analizo in teoretično podprte izračune. Novost naloge je v uporabi matematičnega modeliranja krivulj gibanja kritičnih točk vagona, ki omogoča bolj natančno zaznavanje trkov in boljše prilagajanje različnim geometrijam prog in vagonov.

### 3.4 Metodologija

Pri magistrski nalogi se bomo osredotočili na analitični pristop k zaznavanju trkov med vlakom in tunelom, ki vključuje več korakov. Kot vhodni podatki bodo uporabljeni oblaki točk za vlak in tunel, pridobljeni s 3D laserskim skeniranjem. V prvem koraku bo izvedena predobdelava podatkov, ki vključuje filtriranje šumov in pretvorbo oblakov točk v 2D pogled od zgoraj (bird's-eye view).

Na podlagi 2D podatkov bomo identificirali kritične točke na vlaku (npr. vogali in robovi vagona), ki so ključne za analizo trkov. Nato bomo s pomočjo matematičnih modelov izračunali krivulje, po katerih se te točke gibljejo med prehajanjem vlaka skozi tunel. Metodologija vključuje uporabo izbranega programskega jezika Python za obdelavo podatkov, razvoj modelov in simulacij ter implementacijo algoritmov za detekcijo trkov.

Evalvacija prispevka bo izvedena z analizo rezultatov na podlagi realistično generiranih scenarijev. Učinkovitost in natančnost razvite metode bomo primerjali z obstoječimi metodami, kot so algoritmi za obdelavo oblakov točk s pomočjo k-d dreves. Cilj je pokazati izboljšave v natančnosti in hitrosti analize trkov.

### 3.5 Literatura in viri

- [1] J. Schauer, A. Nüchter, Efficient point cloud collision detection and analysis in a tunnel environment using kinematic laser scanning and k-d tree search, *Int. Arch. Photogramm. Remote Sens. Spatial Inf. Sci.* XL-3 (2014) 289 – 295.  
URL <https://doi.org/10.5194/isprsarchives-XL-3-289-2014>
- [2] J. Klein, G. Zachmann, Point Cloud Surfaces using Geometric Proximity Graphs, *Computers and Graphics* 28 (6) (2004).
- [3] A. Hermann, F. Drews, J. Bauer, S. Klemm, A. Roennau, R. Dillmann, Unified gpu voxel collision detection for mobile manipulation planning, *IEEE International Conference on Intelligent Robots and Systems* (09 2014). doi:10.1109/IROS.2014.6943148.
- [4] T. Niwa, H. Masuda, Interactive collision detection for engineering plants based on large-scale point-clouds, *Computer-Aided Design and Applications* 13 (4) (2016) 511–518. arXiv:<https://doi.org/10.1080/16864360.2015.1131546>, doi:10.1080/16864360.2015.1131546.  
URL <https://doi.org/10.1080/16864360.2015.1131546>
- [5] Y. Li, L. Ma, Z. Zhong, F. Liu, D. Cao, J. Li, M. A. Chapman, Deep learning for lidar point clouds in autonomous driving: A review, *arXiv preprint arXiv:2005.09830* (2020). arXiv:2005.09830.  
URL <https://arxiv.org/abs/2005.09830>

- [6] M. Everett, Y. F. Chen, J. P. How, Collision avoidance in pedestrian-rich environments with deep reinforcement learning, *IEEE Access* 9 (2021) 10357–10377. doi:10.1109/access.2021.3050338.  
URL <http://dx.doi.org/10.1109/ACCESS.2021.3050338>
- [7] T. F. Brustad, R. Dalmo, Railway transition curves: A review of the state-of-the-art and future research, *Infrastructures* 5 (5) (2020). doi:10.3390/infrastructures5050043.  
URL <https://www.mdpi.com/2412-3811/5/5/43>
- [8] L. Jiang, Y. Li, Y. Zhao, M. Cen, The characteristics of long-wave irregularities in high-speed railway vertical curves and method for mitigation, *Sensors* 24 (13) (2024). doi:10.3390/s24134403.  
URL <https://www.mdpi.com/1424-8220/24/13/4403>